

# Introdução à análise exploratória de dados

Wagner H. Bonat  
Elias T. Krainski  
Fernando P. Mayer

Universidade Federal do Paraná  
Departamento de Estatística  
Laboratório de Estatística e Geoinformação

23/02/2018




# Sumário

- 1 Informações gerais
  - O que é estatística?
- 2 Análise exploratória de dados
  - Organização de Dados
  - Tabelas de frequência
  - Representação gráfica
- 3 Exercícios recomendados

# Referência bibliográfica

Livro-texto:

- Marcos Nascimento Magalhães e Antonio Carlos Pedroso de Lima.  
**Noções de Probabilidade e Estatística**. Editora: EDUSP.



# Tópicos do curso

1. Análise exploratória de dados.
2. Probabilidades.
3. Variáveis aleatórias discretas.
4. Medidas resumo.
5. Variáveis bidimensionais.
6. Variáveis aleatórias contínuas.
7. Inferência estatística - Estimação.
8. Inferência estatística - Testes de hipóteses.
9. Tópicos especiais.


# O que é estatística?

- Estatística é um conjunto de técnicas para, sistematicamente:
  - planejar a coleta de dados oriundos de estudos ou experimentos, realizados em qualquer área do conhecimento.
  - descrever, analisar e interpretar dados
  - extrair informações para subsidiar decisões ou conclusões

# Tópicos de estatística básica

- Conceitos essenciais em Estatística:
  - Estatística descritiva.
  - Probabilidade.
  - Inferência estatística.
- Conceitos fundamentais:
  - **População**: Conjunto de todos os elementos sob investigação.
  - **Amostra**: Subconjunto da população.
  - **Variável** de interesse: característica a ser observada em cada indivíduo da amostra

# População e amostra



# Etapas da análise estatística

- Definição do método de coleta de dados
  - estabelecer os objetivos (questões) de pesquisa
  - definir critérios objetivos de como e quais dados coletar
  - postular a análise estatística a ser utilizada



# Etapas da análise estatística

- Definição do método de coleta de dados
  - estabelecer os objetivos (questões) de pesquisa
  - definir critérios objetivos de como e quais dados coletar
  - postular a análise estatística a ser utilizada
- Estatística Descritiva
  - depende do tipo de dado coletado
  - deve ser racionalizada
  - relacionada com os objetivos da pesquisa

# Etapas da análise estatística

- Definição do método de coleta de dados
  - estabelecer os objetivos (questões) de pesquisa
  - definir critérios objetivos de como e quais dados coletar
  - postular a análise estatística a ser utilizada
- Estatística Descritiva
  - depende do tipo de dado coletado
  - deve ser racionalizada
  - relacionada com os objetivos da pesquisa
- Inferência estatística
  - depende do objetivo da pesquisa

# Planejamento da coleta de dados

- definição do experimento
  - variáveis respostas
  - variáveis de controle
  - desenho do experimento e randomização

# Planejamento da coleta de dados

- definição do experimento
  - variáveis respostas
  - variáveis de controle
  - desenho do experimento e randomização
- coleta de dados por amostragem
  - definição da população e característica de interesse
  - definição do plano amostral
    - Aleatória simples (com ou sem reposição) ou sistemática
    - Estratificada, por estratos da população (segundo uma característica)
    - Conglomerados, por grupos de indivíduos da população (subpopulações)
    - Amostragem complexa (combina anteriores)

# Planejamento da coleta de dados

- definição do experimento
  - variáveis respostas
  - variáveis de controle
  - desenho do experimento e randomização
- coleta de dados por amostragem
  - definição da população e característica de interesse
  - definição do plano amostral
    - Aleatória simples (com ou sem reposição) ou sistemática
    - Estratificada, por estratos da população (segundo uma característica)
    - Conglomerados, por grupos de indivíduos da população (subpopulações)
    - Amostragem complexa (combina anteriores)
- coleta de dados observacionais. Exemplos:
  - população de plantas
  - presença de seres vivos num ambiente
  - fenômenos climáticos

# Análise estatística

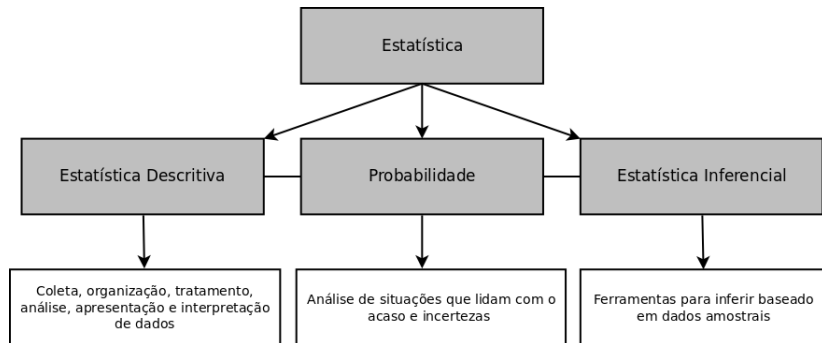
- Estatística Descritiva

- consistência e interpretações iniciais
- visualização dos dados e relações entre variáveis

- Inferência estatística

- estimação de quantidades desconhecidas
- formulação e teste de hipóteses
- extrapolar para a população, se os dados são de uma amostra.

# Etapas da análise estatística



# Sumário

- 1 Informações gerais
  - O que é estatística?
- 2 Análise exploratória de dados
  - Organização de Dados
  - Tabelas de frequência
  - Representação gráfica
- 3 Exercícios recomendados



# Exemplo

Pesquisa foi realizada com alunos. Variáveis:

- **Id**: identificação do aluno; **Turma**: A ou B
- **Sexo**: feminino (F) ou masculino (M)
- **Idade**: em anos; **Alt**: altura em metros
- **Peso**: em quilogramas; **Filhos**: n<sup>o</sup> de filhos na família
- **Fuma**: hábito de fumar: sim (S) ou não (N)
- **Toler**: tolerância ao cigarro: (I) indiferente; (P) incomoda pouco; (M) incomoda muito
- **Exerc.**: horas de atividade física, por semana
- **Cine**: n<sup>o</sup>. de vezes que vai ao cinema por semana
- **Op Cine**: opinião a respeito das salas de cinema na cidade: (B) regular a boa; (M) muito boa
- **TV**: horas gastas assistindo TV, por semana
- **Op TV**: opinião a respeito da qualidade da programação na TV: (R) ruim; (M) média; (B) boa; (N) não sabe.

# Organização de Dados

- A partir de um conjunto de dados coletado, a questão é:
  - Como extrair informações a respeito de uma ou mais características de interesse?
- Basicamente temos duas opções:
  - Tabelas de frequência
  - Gráficos
- O importante é levar em consideração a **natureza dos dados**.


# Organização de Dados

- Uma típica **tabela de dados brutos** contém:
  - Variáveis (características, medições, etc) nas colunas
  - Sujeito (indivíduo, objetos, etc) nas linhas

Id	Turma	Sexo	Idade	Alt	Peso	Filhos	Fuma	Toler	Exerc	Cine	OpCine	TV	OpTV
1	A	F	17	1.60	60.5	2	NAO	P	0	1	B	16	R
2	A	F	18	1.69	55.0	1	NAO	M	0	1	B	7	R
3	A	M	18	1.85	72.8	2	NAO	P	5	2	M	15	R
4	A	M	25	1.85	80.9	2	NAO	P	5	2	B	20	R
5	A	F	19	1.58	55.0	1	NAO	M	2	2	B	5	R
6	A	M	19	1.76	60.0	3	NAO	M	2	1	B	2	R

- Tipos de variáveis:
  - Qualitativa nominal: Turma, Sexo, Fuma,
  - Qualitativa ordinal: Toler, OpCine, OpTV.
  - Quantitativa discreta: Idade, Filh, Exer, Cine, TV.
  - Quantitativa contínua: Alt, Peso.

# Tipos de variáveis



# Tabelas de frequência

- A tabela de dados brutos pode ser muito longa, portanto será difícil extrair alguma informação
- As **tabelas de frequência** ajudam a resumir a informação da variável de interesse
- Vamos usar 3 tipos de frequência:
  - Frequência **absoluta**: contagem de cada valor observado. Representado por  $n_i$  o número de valores  $i$ , e  $n$  o número total
  - Frequência **relativa**: número de valores  $i$  dividido pelo total  $n$ , ou seja  $f_i = \frac{n_i}{n}$
  - Frequência **acumulada**: frequência (absoluta ou relativa) acumulada até um certo valor, obtida pela soma das frequências de todos os valores da variável, menores ou iguais ao valor considerado

# Tabela de frequência - qualitativa nominal

- Considerando a variável Sexo

	$n_i$	$f_i$
F	37	0.74
M	13	0.26
Sum	50	1.00

- Não faz sentido usar frequência acumulada

# Tabela de frequência - quantitativa discreta

- Considerando a variável Idade

	$n_i$	$f_i$	$f_{ac}$
17	9	0.18	0.18
18	22	0.44	0.62
19	7	0.14	0.76
20	4	0.08	0.84
21	3	0.06	0.90
22	0	0.00	0.90
23	2	0.04	0.94
24	1	0.02	0.96
25	2	0.04	1.00
Sum	50	1.00	

# Tabela de frequência - qualitativa ordinal

- Considerando a variável OpTV

	$n_i$	$f_i$	$f_{ac}$
R	39	0.78	0.78
M	1	0.02	0.80
B	3	0.06	0.86
N	7	0.14	1.00
Sum	50	1.00	



# Tabela de frequência - quantitativa contínua

- No caso de quantitativas contínuas não faz sentido contar cada valor pois podem existir muitos
- A solução é criar **classes** ou **faixas de valores**, e contar o número de ocorrências dentro destas classes.
- Para definir as classes:
  1. Defina a amplitude da classe, de maneira que se obtenham de 5 a 8 classes (de mesma amplitude)
  2. Identifique os valores máximo e mínimo da variável e construa as classes de maneira que inclua todos os valores

As classes de valores podem seguir um dos formatos:

Classe	Notação	Denominação	Resultado
$[a, b)$	$a \vdash b$	Fechado em a, aberto em b	Inclui a, não inclui b
$(a, b]$	$a \dashv b$	Aberto em a, fechado em b	Não inclui a, inclui b

# Tabela de frequência - quantitativa contínua

- Considerando a variável Peso
  - Foram construídas 6 classes de amplitude 10
  - As classes são do tipo  $[a, b)$  ou  $a \vdash b$

	$n_i$	$f_i$	$f_{ac}$
[40, 50)	8	0.16	0.16
[50, 60)	22	0.44	0.60
[60, 70)	8	0.16	0.76
[70, 80)	6	0.12	0.88
[80, 90)	5	0.10	0.98
[90, 100)	1	0.02	1.00
<i>Sum</i>	50	1.00	

# Tabela de frequência - quantitativa discreta (muitos valores)

- Considerando a variável TV
- Apesar de ser discreta, a amplitude de valores é muito grande e não seria viável contar as frequências de cada valor
- Nesse caso, utiliza-se o mesmo procedimento para quantitativas contínuas
  - Foram construídas 6 classes de amplitude 6<sup>1</sup>
  - As classes são do tipo  $[a, b)$  ou  $a \vdash b$

	$n_i$	$f_i$	$f_{ac}$
$[0, 6)$	14	0.28	0.28
$[6, 12)$	17	0.34	0.62
$[12, 18)$	11	0.22	0.84
$[18, 24)$	4	0.08	0.92
$[24, 30)$	3	0.06	0.98
$[30, 36)$	1	0.02	1.00
<i>Sum</i>	50	1.00	

<sup>1</sup>Obs.: no livro a tabela tem 5 classes, pois a última tem comprimento 12.


# Representação gráfica

- As informações contidas nas tabelas podem ser visualizadas através de gráficos
- Assim como nas tabelas, existe um tipo de gráfico adequado para cada tipo de variável
- Cuidado deve ser tomado com representações visuais pois um gráfico desproporcional pode gerar interpretações distorcidas
- Os principais são:
  - Diagrama circular (setores ou “pizza”)
  - Gráfico de barras
  - Histograma
  - Boxplot


# Diagrama circular

- Adequado para variáveis qualitativas nominal e ordinal.

**Sexo**




**Toler**



- O uso deste tipo de gráfico deve ser evitado, pois pode ser de difícil interpretação



# Gráfico de barras

- Adequado para variáveis qualitativas nominal/ordinal e quantitativa discreta.
- Podem ser usadas as frequências absolutas ou relativas



# Histograma

- Adequado para quantitativa contínua.



- Altura de cada retângulo é a densidade definida pelo quociente da área pela amplitude da faixa,  $h = \frac{f_i}{AMP}$ .

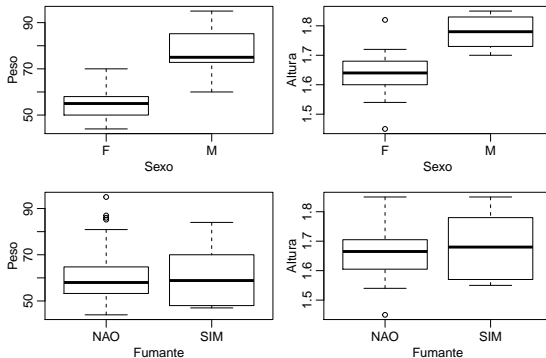
# Mediana e quartis

- **Mediana:** valor da variável que divide o conjunto de dados ordenados em dois subgrupos de mesmo tamanho.
- **Quartis:** valores da variável que divide o conjunto de dados ordenados em quatro subgrupos de mesmo tamanho.
- **Posição dos quartis:**
  - $Q_1 = 0.25 \cdot (N + 1)$  e arredonde.
  - $Q_2 =$  média dos valores nas posições  $(N/2)$  e  $(N/2) + 1$  se  $N$  par e  $Q_2 = (N + 1)/2$  se  $N$  ímpar.
  - $Q_3 = 0.75 \cdot (N + 1)$  e arredonde.
- **Exemplo:** Considere o conjunto de dados: 8.43(1), 8.65(2), 9.96(3), 10.91(4), 10.46(5) e 10.83(6).
  - $Q_1 = 0.25 \cdot 7 = 1.75 \approx 2$ , ou seja 8.65.
  - $Q_2 =$  média dos valores nas posições 3 e 4, ou seja,  $(9.96 + 10.91)/2 = 10.43$ .
  - $Q_3 = 0.75 \cdot 7 = 5.25 \approx 5$ , ou seja, 10.46.



# Boxplots


- Adequado para quantitativa contínua.




- Excelente para explorar relações entre variáveis quantitativas e qualitativas.

# Tipos de simetria


**Assimétrico à esquerda**



**Simétrico**




**Assimétrico à direita**




# Diagrama de dispersão

- Adequado para verificar relação entre variáveis quantitativas.



# Gráfico de mosaico

- Adequado para verificar relação entre variáveis qualitativas (nominais ou ordinais).



# Sumário

- 1 Informações gerais
  - O que é estatística?
- 2 Análise exploratória de dados
  - Organização de Dados
  - Tabelas de frequência
  - Representação gráfica
- 3 Exercícios recomendados

# Exercícios recomendados

- Seção 1.1: Ex. 1, 2 e 3.
- Seção 1.2: Ex. 1 e 4.
- Seção 1.4: Ex. 1, 3, 5 (troque diagrama circular pro gráfico de barras), 8, 9, 12, 18 e 20.