## Estimação: (B) Estimação por intervalo

Wagner H. Bonat Fernando P. Mayer Elias T. Krainski

Universidade Federal do Paraná Departamento de Estatística Laboratório de Estatística e Geoinformação

11/05/2018







#### Sumário

- Introdução
- igl(2) Intervalos de confiança para a média:  $\sigma$  conhecido
  - IC para a média:  $\sigma$  conhecido
  - Determinação do tamanho amostral
- $extcolor{1}{3}$  Intervalos de confiança para a média:  $\sigma$  desconhecido
  - IC para a média:  $\sigma$  desconhecido
  - Determinação do tamanho amostral
- 4 Intervalo de confiança para a proporção p
  - IC para a proporção p
  - Determinação do tamanho amostral
- Exercícios

#### Estimação

Existem dois tipos de estimativas que podemos obter a partir de uma amostra aleatória:

#### Estimativa pontual

Fornecem como estimativa um único valor numérico para o parâmetro de interesse

#### Estimativa intervalar

Fornece um intervalo de valores "plausíveis" para o parâmetro de interesse

## Estimação

Por serem variáveis aleatórias, os estimadores pontuais possuem uma distribuição de probabilidade (distribuições amostrais).

Com isso, podemos apresentar uma estimativa mais informativa para o parâmetro de interesse, que inclua uma medida de **precisão** do valor obtido  $\rightarrow$  **estimativa intervalar** ou **intervalo de confiança**.

Os intervalos de confiança são obtidos a partir da distribuição amostral de seus estimadores.

#### Sumário

- Introdução
- $oxed{2}$  Intervalos de confiança para a média:  $\sigma$  conhecido
  - ullet IC para a média:  $\sigma$  conhecido
  - Determinação do tamanho amostral
- $oxed{3}$  Intervalos de confiança para a média:  $\sigma$  desconhecido
  - IC para a média:  $\sigma$  desconhecido
  - Determinação do tamanho amostral
- 4 Intervalo de confiança para a proporção p
  - IC para a proporção p
  - Determinação do tamanho amostral
- Exercícios

## Suposições necessárias

- A amostra é uma amostra aleatória simples. (Todas as amostras de mesmo tamanho tem a mesma probabilidade de serem selecionadas)
- O valor do desvio padrão populacional  $\sigma$ , é conhecido
- Uma ou ambas das seguintes condições são satisfeitas:
  - A população é normalmente distribuída
  - A amostra possui n > 30

#### Erro amostral

Quando coletamos uma **amostra aleatória** e calculamos uma média, sabemos que o valor da média possui um desvio natural, em relação ao verdadeiro valor da média populacional (**erro amostral**), ou seja

$$e = \bar{X} - \mu \quad \Rightarrow \quad \bar{X} = \mu + e$$

Sabemos que a distribuição amostral da média é uma distribuição normal, com média  $\mu$  e variância  $\sigma^2/n$ ,

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

## Margem de erro

Usando a transformação

$$Z = rac{ar{X} - \mu}{\sigma/\sqrt{n}} = rac{\mathrm{e}}{\sigma/\sqrt{n}} \sim \, \mathsf{N}(0,1)$$

podemos determinar o **erro máximo provável** que assumimos para a média amostral que estamos calculando.

O erro máximo provável ou margem de erro da média é definido por

$$e = z_{\gamma/2} \cdot \frac{\sigma}{\sqrt{n}}$$

onde  $z_{\gamma/2}$  é chamado de valor crítico.

## Intervalo de confiança

Fixando um valor  $\gamma$  tal que 0 <  $\gamma$  < 1, podemos encontrar um valor  $z_{\gamma/2}$  tal que:

$$P[|Z| < z_{\gamma/2}] = \gamma$$

$$P[-z_{\gamma/2} < Z < z_{\gamma/2}] = \gamma$$

$$P[-z_{\gamma/2} < \frac{\bar{x} - \mu}{\sigma/\sqrt{n}} < z_{\gamma/2}] = \gamma$$

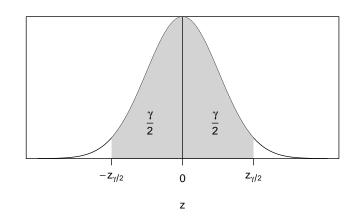
$$P[\bar{x} - z_{\gamma/2} \cdot \left(\frac{\sigma}{\sqrt{n}}\right) < \mu < \bar{x} + z_{\gamma/2} \cdot \left(\frac{\sigma}{\sqrt{n}}\right)] = \gamma$$

$$P[\bar{x} - e < \mu < \bar{x} + e] = \gamma$$

#### Intervalo de confiança

O valor crítico  $z_{\gamma/2}$  é o valor de  $\gamma$  dividido por 2, uma vez que a "massa"  $\gamma$  deve ser distribuída igualmente em torno de 0.





## Coeficiente de confiança $\gamma$

A área  $\gamma$  determina o coeficiente de confiança associado ao intervalo de confiança que estamos construindo.

O valor  $z_{\gamma/2}$  pode ser obtido da tabela da Normal padrão, localizando o valor de  $\gamma/2$  no corpo da tabela e obtendo o valor  $z_{\gamma/2}$  nas margens correspondentes.

Exemplo:  $\gamma = 0,95$ :

- Temos que  $\gamma/2=0,475$  é a área que devemos procurar no corpo da tabela
- O valor de  $z_{\gamma/2}$  será determinado pelos valores correspondentes nas margens da tabela. Nesse caso,  $z_{\gamma/2}=1,96$  é o valor crítico procurado.

## Intervalo de confiança

Com estas definições, podemos construir um intervalo de confiança para  $\mu$ , com coeficiente de confiança  $\gamma$ :

$$\mathsf{IC}(\mu,\gamma) = \left[ \bar{X} - z_{\gamma/2} \cdot \left( \frac{\sigma}{\sqrt{n}} \right); \bar{X} + z_{\gamma/2} \cdot \left( \frac{\sigma}{\sqrt{n}} \right) \right]$$

Outras notações:

$$ar{x} - e < \mu < ar{x} + e$$
 $ar{x} \pm e$ 
 $ar{x} - e; ar{x} + e$ 

# Procedimentos gerais para a construção de intervalos de confiança

- Verifique se as suposições necessárias estão satisfeitas
  - Temos uma AAS
  - $\sigma$  é conhecido
  - A população tem distribuição normal ou n > 30
- f 2 Determine o nível de confiança  $\gamma$ , e encontre o valor crítico  $z_{\gamma/2}$
- 3 Calcule a margem de erro  $e = z_{\gamma/2} \cdot (\sigma/\sqrt{n})$
- Calcule IC( $\mu, \gamma$ )

Suponha que obtivemos um intervalo de 95% de confiança:  $IC(\mu, 95\%) = [52; 58]$ 

#### Interpretação 1

Temos 95% de confiança de que a verdadeira média populacional  $\mu$  se encontra entre 52 e 58

#### Interpretação 2

Temos 95% de confiança de que o intervalo entre 52 e 58 realmente contém a verdadeira média populacional  $\mu$ 

Suponha que obtivemos um intervalo de 95% de confiança:  $IC(\mu, 95\%) = [52; 58]$ 

#### Interpretação 1 — ERRADA

Temos 95% de confiança de que a verdadeira média populacional  $\mu$  se encontra entre 52 e 58

#### Interpretação 2 — CERTA

Temos 95% de confiança de que o intervalo entre 52 e 58 realmente contém a verdadeira média populacional  $\mu$ 

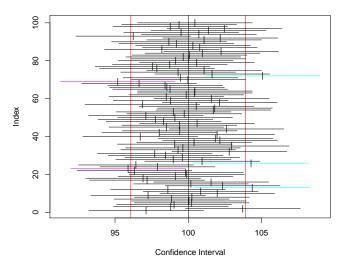
Como o intervalo de confiança é calculado a partir de uma amostra aleatória, este intervalo também é aleatório!

Isso significa que para cada amostra aleatória que tivermos, um intervalo diferente será calculado.

Como o valor de  $\mu$  é fixo, é o intervalo que deve conter o valor de  $\mu$ , e não o contrário.

Isso significa que se pudessemos obter 100 amostras diferentes, e calcularmos um intervalo de confiança de 95% para cada uma das 100 amostras, esperariamos que 5 destes intervalos **não** contenham o verdadeiro valor da média populacional  $\mu$ .

#### Confidence intervals based on z distribution



#### Exemplo

Uma empresa de computadores deseja estimar o tempo médio de horas semanais que as pessoas utilizam o computador.

Uma amostra aleatória de 25 pessoas apresentou um tempo médio de uso de 22,4 horas. Com base em estudos anteriores, a empresa assume que  $\sigma=5,2$  horas, e que os tempos são normalmente distribuídos.

Construa um intervalo de confiança para a média  $\mu$  com coeficiente de confiança de 95%.

#### Amplitude de um intervalo

A amplitude de um intervalo de confiança é dada pela diferença entre o limite superior e inferior, ou seja,

$$\mathsf{AMP}_{IC} = \left[ \bar{x} + z_{\gamma/2} \cdot \left( \frac{\sigma}{\sqrt{n}} \right) \right] - \left[ \bar{x} - z_{\gamma/2} \cdot \left( \frac{\sigma}{\sqrt{n}} \right) \right]$$
$$= 2 \times z_{\gamma/2} \cdot (\sigma/\sqrt{n})$$

- Note que, claramente, um intervalo de confiança depende conjuntamente de três componentes:
  - Coeficiente de confiança  $\gamma$ , expresso pelo valor crítico  $z_{\gamma/2}$
  - ullet Desvio-padrão populacional  $\sigma$
  - Tamanho da amostra n

#### Amplitude de um intervalo

 $z_{\gamma/2} \to {\sf Cada}$  vez que aumentamos a confiança  $\gamma$ , o valor de  $z_{\gamma/2}$  fica maior, e consequentemente a amplitude do intervalo aumenta.

 $\sigma \to \mathsf{Um}$  grande desvio padrão indica a possibilidade de um considerável distanciamento dos valores amostrais em relação à média populacional

n o Quanto maior for o tamanho da amostra, maior será a quantidade de informação disponível. Com isso, valores maiores de n produzem intervalos mais informativos

## Exemplo

#### Seja $X \sim N(\mu, 36)$

- Para uma amostra de tamanho 50, obtivemos média amostral 18,5.
   Construa intervalos de confiança de
  - (i) 90% (ii) 95% (iii) 99%
- Calcule as amplitudes dos intervalos acima e explique a diferença.
- Para um nível de confiança de 95%, construa intervalos de confiança (admita a mesma média amostral 18,5) supondo tamanhos de amostra
  - (i) n = 15 (ii) n = 100
- Calcule as amplitudes dos intervalos acima e explique a diferença.

Nosso objetivo é coletar dados para estimar a **média populacional**  $\mu$ .

A questão é:

Quantos elementos (itens, objetos, pessoas, ...) devemos amostrar?

Já vimos que, de maneira (bem) geral, n > 30 é um tamanho de amostra mínimo para a maioria dos casos.

Será que podemos ter uma estimativa melhor de quantos elementos devem ser amostrados para estimarmos a média populacional com uma precisão conhecida?

A partir da equação do erro máximo provável

$$e = z_{\gamma/2} \cdot \frac{\sigma}{\sqrt{n}}$$

podemos isolar n e chegar na seguinte equação para a determinação do tamanho amostral

$$n = \left[\frac{z_{\gamma/2} \cdot \sigma}{e}\right]^2$$

Note que, em

$$n = \left[\frac{z_{\gamma/2} \cdot \sigma}{e}\right]^2$$

- O tamanho amostral n não depende do tamanho populacional N
- O tamanho amostral depende:
  - do nível de confiança desejado (expresso pelo valor crítico  $z_{\gamma/2}$ )
  - do erro máximo desejado
  - ullet do desvio-padrão  $\sigma$  (embora veremos que não é estritamente necessário)
- Como o tamanho amostral precisa ser um número inteiro, arredondamos sempre o valor para o maior número inteiro mais próximo

#### Exemplo

#### Seja $X \sim N(\mu, 36)$

- O Calcule o tamanho da amostra, para que com 95% de probabilidade, a média amostral não difira da média populacional por mais de
  - (i) 0,5 unidades (ii) 2 unidades
- Qual o impacto do erro máximo assumido para o tamanho da amostra?
- Calcule o tamanho da amostra, para que a diferença da média amostral para a média populacional (em valor absoluto) seja menor ou igual a 2 unidades, com níveis de confiança de
  - (i) 90% (ii) 95%
- Compare as estimativas do item anterior e analise o impacto do nível de confiança para a determinação do tamanho amostral.

#### Sumário

- Introdução
- $\, igotimes_{}^{}$  Intervalos de confiança para a média:  $\, \sigma \,$  conhecido
  - IC para a média:  $\sigma$  conhecido
  - Determinação do tamanho amostral
- $oldsymbol{3}$  Intervalos de confiança para a média:  $\sigma$  desconhecido
  - ullet IC para a média:  $\sigma$  desconhecido
  - Determinação do tamanho amostral
- 4 Intervalo de confiança para a proporção p
  - IC para a proporção p
  - Determinação do tamanho amostral
- Exercícios

#### Estimativa da variância amostral

Na maioria das situações práticas, não sabemos o verdadeiro valor do desvio padrão populacional  $\sigma$ .

Se o desvio padrão é desconhecido, ele precisa ser estimado.

Sendo  $(X_1, \ldots, X_n)$  VAs onde  $X \sim N(\mu, \sigma^2)$ , vimos que o "melhor" estimador para  $\sigma^2$  é a variância amostral

$$S^{2} = \frac{1}{n-1} \left( \sum_{i=1}^{n} X_{i}^{2} - n\bar{X}^{2} \right)$$

que é não viciada e consistente para  $\sigma^2$ .

## A distribuição t de Student

Definindo a variável padronizada

$$T = \frac{\bar{X} - \mu}{\sqrt{S^2/n}} = \frac{\bar{X} - \mu}{S/\sqrt{n}}$$

o denominador  $S^2$  fará com que a função densidade de T seja diferente da Normal.

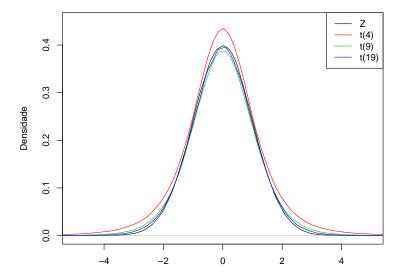
Essa nova densidade é denominada t de Student, e seu parâmetro é denominado graus de liberdade, que nesse caso é n-1. Assim:

$$T = rac{ar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$$

# Características da distribuição t

- É simétrica com média t = 0 (assim como z = 0)
- É diferente para tamanhos de amostra diferentes
- O desvio padrão da distribuição t varia com o tamanho da amostra (ao contrário da distribuição z onde  $\sigma=1$ )
  - $\begin{array}{ccc} \bullet & n \downarrow & \sigma \uparrow \\ \bullet & n \uparrow & \sigma \downarrow \end{array}$
- A medida que o n amostral aumenta, a distribuição t se aproxima cada vez mais de uma distribuição normal padrão Z
  - Por isso, para amostras grandes (n > 30) o resultado das duas é similar

## Características da distribuição t

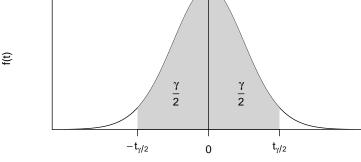


#### Encontrando valores críticos de t

Com a definição do **nível de confiança** e sabendo o tamanho da amostra n, sabemos então o valor de  $\gamma$  e dos gl, e devemos encontrar o **valor crítico** de  $t_{\gamma/2}$ . Usando como exemplo  $\gamma=0,95$  e uma amostra de n=7

- Temos que  $n = 7 \Rightarrow gl = n 1 = 6$
- Na tabela da distribuição t de Student procure a linha correspondente aos gl, e coluna correspondente ao valor de  $1-\gamma=1-0.95=0.05=5\%$
- O valor de  $t_{\gamma/2}$  será determinado pelos valores correspondentes no corpo da tabela. Nesse caso,  $t_{\gamma/2}=2,447$  é o valor crítico procurado.

#### Encontrando valores críticos de t



## Intervalo de confiança

Com estas definições, podemos construir um intervalo de confiança para  $\mu$ , com coeficiente de confiança  $\gamma$ , e  $\sigma$  desconhecido:

$$\mathsf{IC}(\mu,\gamma) = \left[ \bar{X} - t_{\gamma/2} \cdot \left( \frac{S}{\sqrt{n}} \right); \bar{X} + t_{\gamma/2} \cdot \left( \frac{S}{\sqrt{n}} \right) \right]$$

Outras notações:

$$ar{x} - e < \mu < ar{x} + e$$
 $ar{x} \pm e$ 
 $ar{x} - e; ar{x} + e$ 

# Procedimentos gerais para a construção de intervalos de confiança

- Verifique se as suposições necessárias estão satisfeitas
  - Temos uma AAS
  - Temos uma estimativa de s
  - A população tem distribuição normal ou n > 30
- f 2 Determine o nível de confiança  $\gamma$ , e encontre o valor crítico  $t_{\gamma/2}$
- $oldsymbol{3}$  Calcule a margem de erro  $e=t_{\gamma/2}\cdot (S/\sqrt{n})$
- Calcule IC( $\mu, \gamma$ )

#### Exemplo

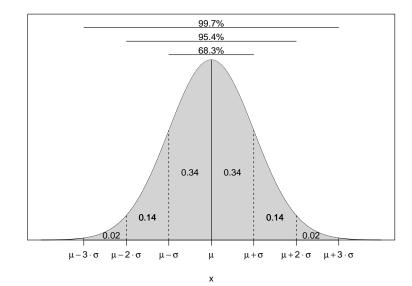
Em um teste da eficácia do alho na dieta para a redução do colesterol, 51 pessoas foram avaliadas e seus níveis de colesterol foram medidos antes e depois do tratamento. As **mudanças** nos níveis de colesterol apresentaram média de 0,4 e desvio-padrão de 21.

- Para um nível de confiança de 95%, calcule o intevalo para a verdadeira média das mudanças no nível de colesterol
- O que o intervalo de confiança sugere sobre a eficácia do uso do alho na dieta para a redução do colesterol?
- ② Resolva o mesmo exemplo supondo que o  $\sigma = s$  é conhecido (ou seja, usando a distribuição Z). Compare os dois métodos.

#### Se $\sigma$ for desconhecido?

- ullet Estime o valor de  $\sigma$  com base em algum estudo feito anteriormente
- Faça uma amostra piloto e estime o desvio padrão amostral s, e use-o como uma aproximação para o desvio-padrão populacional  $\sigma$
- Use a regra empírica da amplitude para dados com distribuição (aproximadamente) normal

# Regra empírica para uma distribuição normal



(X

## Regra empírica para uma distribuição normal

Define-se valores usuais aqueles que são típicos e não muito extremos.

Como sabemos que em uma distribuição (aproximadamente) normal, aproximadamente 95% dos dados encontram-se a 2 desvios-padrões acima e abaixo da média, temos que

$$4\sigma = (\max - \min)$$
$$\sigma = \frac{(\max - \min)}{4}$$

pode ser utilizado como uma estimatva para  $\sigma$ .

### Exemplo

Um professor deseja estimar o salário médio de professores do ensino médio de uma cidade. Quantos professores devem ser selecionados para termos 90% de confiança que a média amostral esteja a menos de R\$30,00 da média populacional? Sabe-se apenas que os salários variam entre R\$800,00 e R\$1.200.00.

Use

$$n = \left[\frac{z_{\gamma/2} \cdot \sigma}{e}\right]^2$$

#### Sumário

- Introdução
- $\, igotimes_{}^{}$  Intervalos de confiança para a média:  $\, \sigma \,$  conhecido
  - IC para a média:  $\sigma$  conhecido
  - Determinação do tamanho amostral
- extcoloredIntervalos de confiança para a média:  $\sigma$  desconhecido
  - ullet IC para a média:  $\sigma$  desconhecido
  - Determinação do tamanho amostral
- Intervalo de confiança para a proporção p
  - IC para a proporção p
  - Determinação do tamanho amostral
- Exercícios

## Proporção amostral

A proporção amostral

$$\hat{p} = \frac{x}{n} = \frac{\text{número de sucessos}}{\text{total de tentativas}}$$

é a "melhor estimativa" para a proporção populacional p

Através do estudo da distribuição amostral da proporção, chegamos aos seguintes resultados:

- ullet A proporção amostral  $\hat{p}$  tende para o valor da proporção populacional p
- A distribuição das proporções amostrais tende a ser uma distribuição normal
- $\mathsf{E}(\hat{p}) = \mu_{\hat{p}} = p$
- $\operatorname{Var}(\hat{p}) = \sigma_{\hat{p}}^2 = \frac{p(1-p)}{n}$

# Distribuição amostral da proporção $\hat{p}$

Assim, sabemos que

$$\hat{p} \sim \mathsf{N}\left(p, \frac{p(1-p)}{n}\right)$$

Ainda podemos mostrar que a quantidade

$$Z = rac{\hat{p} - p}{\sqrt{rac{p(1-p)}{n}}} \sim N(0,1)$$

### Erro amostral da proporção

O erro amostral da proporção pode ser definido por

$$e = \hat{p} - p \quad \Rightarrow \quad p = \hat{p} + e$$

então

$$Z = rac{\hat{p} - p}{\sqrt{rac{p(1-p)}{n}}} = rac{e}{\sqrt{rac{p(1-p)}{n}}} \sim \mathsf{N}(0,1)$$

Portanto o erro máximo provável ou margem de erro da proporção é

$$e = z_{\gamma/2} \cdot \sqrt{\frac{p(1-p)}{n}}$$

## Intervalo de confiança

Com estas definições, podemos construir um intervalo de confiança para p, com coeficiente de confiança  $\gamma$ 

$$\mathsf{IC}(p,\gamma) = \left[\hat{p} - z_{\gamma/2} \cdot \sqrt{\frac{p(1-p)}{n}}; \hat{p} + z_{\gamma/2} \cdot \sqrt{\frac{p(1-p)}{n}}\right]$$

Outras notações:

$$\hat{
ho}-e  $\hat{
ho}\pm e$   $[\hat{
ho}-e;\hat{
ho}+e]$$$

# Procedimentos gerais para a construção de intervalos de confiança

- Verifique se as suposições necessárias estão satisfeitas
  - Temos uma AAS
  - As condições para a distribuição binomial são satisfeitas
    - as tentativas são independentes
    - há duas categorias de resultado ("sucesso", "fracasso")
    - a probabilidade de sucesso p permanece constante
  - A distribuição normal pode ser usada como aproximação para a distribuição binomial, ou seja,  $np \ge 5$  e  $np(1-p) \ge 5$
- ② Determine o nível de confiança  $\gamma$ , e encontre o valor crítico  $z_{\gamma/2}$
- **3** Calcule a margem de erro  $e = z_{\gamma/2} \cdot \sqrt{\frac{p(1-p)}{n}}$
- Calcule  $IC(p, \gamma)$

## Intervalo de confiança

Uma possível dificuldade nessa abordagem é que em geral não conhecemos o verdadeiro valor de p para calcular o IC.

Quando **não conhecemos** a proporção populacional p, temos duas alternativas:

- **1** Usar  $\hat{p}$  no lugar de p (estimativa otimista)
- ② Usar p = 0, 5 (estimativa conservadora). Porque quando p = 0, 5, o termo p(1-p) terá valor máximo.

p	(1 - p)	p(1 - p)
0,1	0,9	0,09
0,3	0,7	0,21
0,5	0,5	0,25
0,6	0,4	0,24
0,8	0,2	0,16

### Exemplo

Em uma pesquisa realizada por um instituto de pesquisa Norte-Americano, 1500 adultos foram selecionados aleatoriamente para responder à pergunta se acreditam ou não no aquecimento global. 1050 entrevistados respoderam que sim. Com isso:

- Para um nível de confiança de 95%, calcule o intervalo de confiança para a verdadeira proporção de pessoas que acreditam no aquecimento global, utilizando:
  - (i)  $p = \hat{p}$  e (ii) p = 0, 5 e compare os resultados.
- Com base nesses resultados, podemos concluir que a maioria dos adultos acredita no aquecimento global?

## Determinação do tamanho amostral

A partir da equação do erro máximo provável

$$e=z_{\gamma/2}\cdot\sqrt{\frac{p(1-p)}{n}}$$

podemos isolar n e chegar na seguinte equação para a determinação do tamanho amostral para uma proporção populacional

$$n = \left(\frac{z_{\gamma/2}}{e}\right)^2 \cdot p(1-p)$$

Quando não conhecemos p, usamos  $\hat{p}$  (estimativa otimista) ou p=0,5 (estimativa conservadora) como estimativas de p.

### Exemplo

Um fabricante de peças deseja estimar a verdadeira proporção de peças defeituosas no processo de fabricação, com um erro máximo de 3% e nível de confiança de 99%. Calcule o tamanho da amostra necessário para se estimar esta proporção se:

- O fabricante tem uma estimativa de que em uma amostra anterior, aproximadamente 10% das peças eram defeituosas.
- O fabricante não tem nenhuma informação prévia sobre a proporção de peças defeituosas.

### Sumário

- Introdução
- $\bigcirc$  Intervalos de confiança para a média:  $\sigma$  conhecido
  - ullet IC para a média:  $\sigma$  conhecido
  - Determinação do tamanho amostral
- $\bigcirc$  Intervalos de confiança para a média:  $\sigma$  desconhecido
  - ullet IC para a média:  $\sigma$  desconhecido
  - Determinação do tamanho amostral
- 4 Intervalo de confiança para a proporção p
  - IC para a proporção p
  - Determinação do tamanho amostral
- Exercícios

### Exercícios recomendados

- Seção 7.4 1 a 5
- Seção 7.5 17, 19, 21, 23, 25, 29
- Seção 8.3 (distribuição t) 1